

基于深度信念网络的变压器油中 溶解气体浓度预测方法

代杰杰¹, 宋辉¹, 杨祎², 陈玉峰², 盛戈皞¹, 江秀臣¹

(1. 上海交通大学 电气工程系, 上海市 闵行区 200240;

2. 国网山东省电力公司 电力科学研究院, 山东省 济南市 250002)

Concentration Prediction of Dissolved Gases in Transformer Oil Based on Deep Belief Networks

DAI Jiejie¹, SONG Hui¹, YANG Yi², CHEN Yufeng², SHENG Gehao¹, JIANG Xiuchen¹

(1. Department of Electrical Engineering, Shanghai Jiaotong University, Minhang District, Shanghai 200240, China;

2. Electric Power Research Institute of Shandong Power Supply Company of State Grid, Jinan 250002, Shandong Province, China)

ABSTRACT: Prediction of development trend of gas concentration dissolved in transformer oil can provide important basis for transformer condition assessment. A new prediction model based on deep belief networks is proposed. Seven types of characteristic gas concentration combined with environment temperature and transformer oil temperature are fed to input layer. The model can automatically extract regulation of gas concentration development trend through training a multi-hidden-layer machine learning model based on restricted Boltzmann machine. Correlation between different types of gases and influence of temperatures is activated layer by layer. Irrelevant and redundant information is inhibited by the model. The proposed method has higher prediction accuracy. It overcomes drawbacks of low stability in traditional methods and shortcoming of considering only one characteristic gas. In addition, it avoids manual intervention in calculation process. Finally, case analysis verifies effectiveness and superiority of the proposed model.

KEY WORDS: transformer; dissolved gas in oil; deep belief networks; correlation; predict

摘要: 对油中溶解气体浓度发展趋势进行预测, 可为变压器状态评估提供重要依据。提出一种基于深度信念网络的变压器油中溶解气体浓度预测模型。该模型以 7 种特征气体浓度、环境温度、变压器油温为可视输入, 通过对基于受限玻尔兹曼机的多隐层机器学习模型训练, 可自动提取气体浓度

自身发展规律, 逐层激活各气体组分之间及温度对气体浓度影响的强相关性, 抑制、弱化无关和冗余信息。该模型具有较高预测精度, 克服了传统单一变量预测方法稳定性差的问题, 同时避免了人工干预过程。通过算例分析, 验证了该方法的有效性。

关键词: 变压器; 油中溶解气体; 深度信念网络; 相关性; 预测

DOI: 10.13335/j.1000-3673.pst.2016.2623

0 引言

电力变压器是电力系统的关键设备之一, 其运行状态关乎电网能否可靠供电。变压器在运行使用过程中, 由于老化、电、热故障等原因会产生少量气体溶解于绝缘油中, 油中气体的各种成分含量及不同组分间的比例关系与变压器运行状况密切相关。通过油中溶解气体分析(dissolved gas analysis, DGA)^[1-3]可发现变压器内部某些潜伏性故障及其发展程度, 此项技术已被大量故障诊断的实践所证明, 是目前国际公认的一种诊断变压器早期故障的有效方法。对油中溶解气体浓度发展趋势进行预测, 可为变压器状态评估提供重要依据, 具有重要现实意义^[4-5]。

国内外众多学者对油中溶解气体浓度预测进行了大量研究, 一般多采用灰色模型(grey model, GM)、人工神经网络(artificial neural network, ANN)、支持向量机(support vector machine, SVM)及组合预测等方法^[6-9]。传统的方法在建模时往往只考虑某种气体发展趋势, 忽略了气体间的关联性分析, 使得预测效果不够科学, 稳定性较差。为解

基金项目: 国家自然科学基金项目(51477100); 国家 863 高技术基金项目(2015AA050204); 国家电网公司科技项目(520626150032)。

Project Supported by National Natural Science Foundation of China (NSFC) (51477100); Project Supported by the National High Technology Research and Development of China (863 Programme) (2015AA050204); Project Supported by Science and Technology Foundation of State Grid Corporation of China (520626150032).

决这个问题,文献[10-12]引入灰关联计算,考虑到各组间相关性,在预测前采用灰关联度分析对输入变量进行相关性定量分析,剔除相关性较弱的影响因素,再利用上述预测方法建模计算。此外,文献[13]针对输入变量的选择问题,改进了标准化互信息变量选择算法,在特征选择评估标准中引入条件互信息取代原有的互信息项,在一定程度上提高了输入变量的选择有效性。灰关联和互信息技术虽然避免了单一组分气体浓度预测的缺陷,但数据预处理过程中增加了计算量,并且关联度阈值在选取上有一定的主观性。随着深度学习方法的的发展,深度信念网络的特征提取能力在变压器故障分类建模、模式识别、时间序列预测等方面展现出一定的优势^[14-16],为电力领域数据处理提供了新的思路。

鉴于此,本文提出一种基于深度信念网络(deep belief network, DBN)^[17]的油中溶解气体浓度预测方法。利用 DBN 强大的特征学习能力,构建多隐层机器学习模型,自动提取各气体组分及环境因素(气温、油温)之间的相关特性,进行气体浓度预测。既解决了单一变量预测稳定性差的问题,又避免了预处理的大量计算,最小化了人工干预的过程。该方法利用工程现场大量样本数据训练学习,提取不同变化趋势下信息特征和潜在的统计规律,实验结果证明该方法有较高预测精度。

1 油中溶解气体浓度预测

正常运行状态下的变压器,因绝缘油和固体绝缘的老化裂解等会分解出极少量气体,主要为氢气 H_2 、甲烷 CH_4 、乙烷 C_2H_6 、乙烯 C_2H_4 、乙炔 C_2H_2 、一氧化碳 CO 、二氧化碳 CO_2 。当变压器内部发生故障或异常时,这些气体中的某些组分含量会迅速增加。例如绝缘油过热时, CH_4 和 C_2H_4 为主要增大的气体成分,且表现出较强相关性;高能放电时 H_2 和 C_2H_2 含量升高,且表现出较强相关性。因此,对变压器油中溶解气体浓度进行预测时,应考虑气体组分间的相互影响关系。据有关资料介绍,对多台故障变压器的统计表明过热性故障占 63%^[1],温度与溶解气体含量之间存在一定的对应关系,因此本文将环境温度和油温作为相关性因素。

变压器油中溶解气体浓度单一变量序列可表示为 $X^m = \{x_{t-k}^m, x_{t-k+1}^m, \dots, x_t^m, x_{t+1}^m, \dots\}$, 其中 x_t^m 表示第 m 种气体在时刻 t 的测量值。考虑各组分及环境因素相关性,序列可表示为 $X = \{X^1, X^2, \dots, X^D\}$, D 表示相关变量个数,因此可将气体浓度预测视为多变量复杂度较高的预测问题。若 $x_{t+\tau}$ 与其前 K 个

数据相关,则预测任务可描述为 $x_{t+\tau} = f(x_{t-K}, \dots, x_{t-1}, \theta)$ 其中 θ 为 f 模型中参数向量。预测值为 $\hat{x}_{t+\tau} = f(x_{t-K}, \dots, x_{t-1}, \hat{\theta})$, 则代价函数如式(1)所示。

$$J(\theta) = \frac{1}{n} \sum_{t=1}^n (x_{t+\tau} - \hat{x}_{t+\tau})^2 \quad (1)$$

对于模型 f_{θ} 寻找最优 $\hat{\theta}$ 使得代价函数 J 最小,预测值尽可能逼近实际值以达到预测效果。

2 深度信念网络模型

深度信念网络由 Geoffrey Hinton^[18]在 2006 年提出,它是由多层受限玻尔兹曼机(restricted Boltzmann machine, RBM)组成的一种生成模型,在特征识别、数据降维、分类预测等方面性能突出,目前被广泛应用于图像处理、语音识别等领域^[19-21],本文利用其自动提取训练数据特征规律来实现预测功能。

2.1 受限玻尔兹曼机

受限玻尔兹曼机是一种可用随机神经网络解释的概率图模型^[22]。可视层 v 由显元 v_i 组成,用于输入训练数据;隐藏层 h 由隐元 h_j 组成,用作为特征检测器。图 1 为 RBM 网络结构,由图 1 可看出 RBM 层内无连接,层间全连接^[23]。




图 1 RBM 网络结构

Fig. 1 Structure of RBM

RBM 是一种基于能量的模型,对一组给定状态 (v, h) , 其联合组态能量定义如下:

$$E_{\theta}(v, h) = -\sum_{i=1}^{n_v} a_i v_i - \sum_{j=1}^{n_h} b_j h_j - \sum_{i=1}^{n_v} \sum_{j=1}^{n_h} h_j w_{j,i} v_i \quad (2)$$

式中: a_i 和 b_j 分别为显元 i 和隐元 j 的偏置; $w_{j,i}$ 为显元 i 和隐元 j 之间的连接权重; $\theta = \{w_{j,i}, a_i, b_j\}$ 为模型参数。

基于能量函数,状态 (v, h) 的联合概率分布为

$$P_{\theta}(v, h) = \frac{1}{Z_{\theta}} e^{-E_{\theta}(v, h)} \quad (3)$$

式中: $Z_{\theta} = \sum_{v, h} e^{-E_{\theta}(v, h)}$ 为归一化因子,也被称为配分函数。

对一组观测数据 v 的分布 $P_{\theta}(v)$ 联合概率分布

$P_{\theta}(v, h)$ 的边缘分布也称为似然函数, 定义如式(4):

$$P_{\theta}(v) = \sum_h P_{\theta}(v, h) = \frac{1}{Z_{\theta}} \sum_h e^{-E_{\theta}(v, h)} \quad (4)$$

同样, 可得到式(5):

$$P_{\theta}(h) = \sum_v P_{\theta}(v, h) = \frac{1}{Z_{\theta}} \sum_v e^{-E_{\theta}(v, h)} \quad (5)$$

由 RBM 特殊的网络结构可知, 显元及隐元的状态和激活条件独立。第 j 个隐元的激活概率为

$$P(h_j = 1 | v) = \text{sigmoid}(b_j + \sum_{i=1}^{n_v} w_{ji} v_i) \quad (6)$$

同样可得到第 i 个显元激活概率为

$$P(v_i = 1 | h) = \text{sigmoid}(a_i + \sum_{j=1}^{n_h} w_{ij} h_j) \quad (7)$$

式中: $\text{sigmoid}(x) = 1/(1 + e^{-x})$ 为神经网络的激活函数, 将变量 x 映射到 0~1 之间。

给定训练样本后, 训练 RBM 以调整参数 θ , 使得该参数控制下的 RBM 表示的概率分布尽可能与训练数据的分布相符, 最大化如下似然可达到训练 RBM 的目的。

$$\ln L_{\theta, S} = \ln \prod_{i=1}^{n_s} P(v^i) = \sum_{i=1}^{n_s} \ln P(v^i) \quad (8)$$

式中: S 为训练样本集合; n_s 为训练样本个数。

为求式(8)表示的极大对数似然函数, 通常采用随机梯度上升法, 见式(9)。

$$\frac{\partial \ln L_{\theta, S}}{\partial \theta} = \frac{\partial \ln P(v)}{\partial \theta} = - \left\langle \frac{\partial E(v, h)}{\partial \theta} \right\rangle_{P(h|v)} + \left\langle \frac{\partial E(v, h)}{\partial \theta} \right\rangle_{P(v, h)} \quad (9)$$

其中 $\langle \rangle_p$ 表示关于分布 P 的数学期望。

因为归一化因子 Z_{θ} 的存在, 联合概率分布 P 求解较为复杂。Hinton 在 2002 年提出对比散度 (contrastive divergence, CD) 算法^[24], 在训练过程中, 首先将显元向量映射到隐元, 然后用隐元重构显元向量, 再将显元向量映射到隐元, 重复执行以上步骤 k 次, 最终实现对 RBM 的快速训练学习。

2.2 基于深度信念网络的预测模型

DBN 由多层 RBM 构成, 其相邻两层可分解为一个单独的 RBM, 通过神经元的激活或抑制状态, 表征各状态间相关程度。单变量 DBN 预测模型网络结构如图 2 所示, 可视层显元为输入的某一种气体浓度序列向量, 输入维度 K 代表预测值与其前 K 个数据相关。通过对该气体浓度动态发展过程训练学习, 得到神经元状态及模型参数 θ , 单变量模型参数 θ 仅提取该气体浓度自身发展趋势规律。

本文所用 DBN 多变量 (multivariable deep belief network, MDBN) 预测模型结构如图 3 所示, 可视

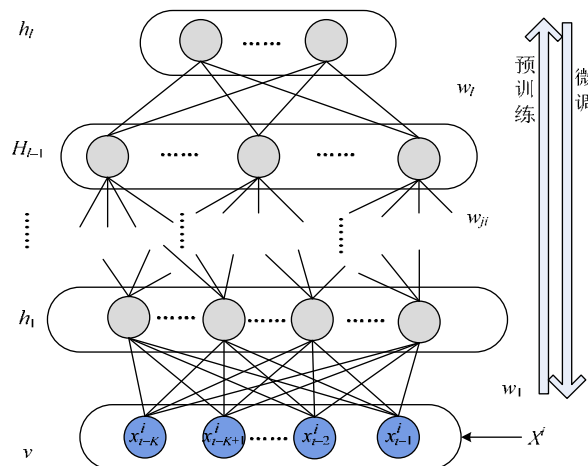


图2 单变量 DBN 预测模型

Fig. 2 Univariate prediction model of DBN

层神经元为 H_2 、 CH_4 等 7 种油中溶解气体浓度及油温和环境温度向量, 其中各状态向量为 K 维序列。对某种气体浓度预测时, MDBN 模型依据序列数据统计关系的特征提取, 确定该气体浓度自身时间维度的相关性。同时从油中溶解气体浓度、油温及环境温度高维复杂的输入数据中提取抽象的相关特征, 逐层激活强相关影响因素, 抑制、弱化无关和冗余信息。

DBN 网络使用非监督贪婪逐层方法预训练模型得到权重。图 3 中, 对训练集中的每条记录 x 依据一定的规则输入到可视层, 采用 CD 算法逐层训练各 RBM 网络。

由于每一层 RBM 网络都是独立进行训练, 只能保证该层的权重对该层特征向量映射达到最优, 并不能保证整个 DBN 网络特征提取和映射达到最优。因此采用梯度下降算法将网络输出与标准数值标签之间的误差自顶向下反向传播至每一层 RBM,

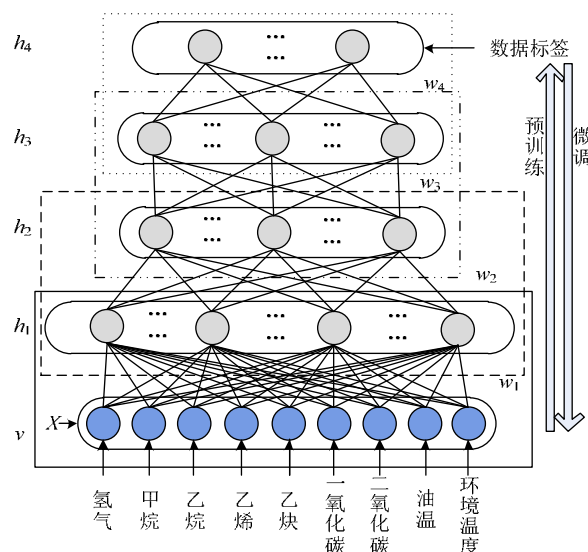


图3 MDBN 预测模型

Fig. 3 Prediction model of MDBN

微调整个 DBN 模型 ,实现模型参数最优化。MDBN 模型训练步骤如表 1 所示。

表 1 MDBN 模型训练步骤	
Tab. 1 Training steps of MDBN model	
训练步骤	内容
Step1 初始化	给定训练样本, 设定训练周期 epoch, 学习率 γ ; 指定可见层及隐层单元数目 n_v 和 n_h ; 初始化权重矩阵 W , 偏置向量 a, b 。
Step2 CD 算法训练各层 RBM	将训练样本 x 赋给显层 $v^{(0)}$, 根据式(6)计算对应的隐元被激活的概率 $P(h_j^{(0)}=1 v^{(0)})$; 从计算得到的概率分布中抽取一个样本 $h^{(0)} \sim P(h^{(0)} v^{(0)})$, 用 $h^{(0)}$ 重构显层 $P(v_i^{(1)}=1 h^{(0)})$; 抽取重构的显层中一个样本 $v^{(1)} \sim P(v^{(1)} h^{(0)})$, 用 $v^{(1)}$ 计算隐元被激活的概率 $P(h_j^{(1)}=1 v^{(1)})$; 更新权重 $W \leftarrow W + \gamma[(P(h^{(0)}=1 v^{(0)})v^{(0)T} - P(h^{(1)}=1 v^{(1)})v^{(1)T})]$ $a \leftarrow a + \gamma[v^{(0)} - v^{(1)}]$ $b \leftarrow b + \gamma[P(h^{(0)}=1 v^{(0)}) - P(h^{(1)}=1 v^{(1)})]$ 。
Step3 微调	对输出层数据,依据代价函数式(1)采用梯度下降法反向传播至各层 RBM, 微调权重参数

基于 MDBN 的变压器油中溶解气体浓度预测方法建模及预测步骤如下：

- 1) 收集变压器油色谱数据，选取特征参量为 H_2 、 CH_4 、 C_2H_6 、 C_2H_4 、 C_2H_2 、 CO 、 CO_2 浓度、环境温度和油温向量，划分训练样本及测试样本。
- 2) 将各参量数据分别按照离差标准化方法映射到[0-1]之间，转换函数为 $x^* = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$ ，其中 x_{\min} 为样本数据最小值， x_{\max} 为样本数据最大值。
- 3) 将训练样本按照表 1 训练步骤进行特征提取学习，保存训练好的网络模型参数。
- 4) 利用步骤 3) 中所得网络模型对测试样本进行预测。

确定模型输入输出均为 27,隐藏层中隐元数目为 100,即网络结构为 27-100-100-.....-100-27。经过实验发现,网络结构层数和训练周期与预测准确率有一定关系,如图 4 所示。当训练周期固定,网络层数从 1 层增加至 4 层,预测正确率大幅提升,由 4 层增加至 7 层,准确率提升效果微弱。当网络结构确定时,随着训练周期增加,预测准确率呈上升趋势,且趋势逐渐变缓。综合模型预测效果及运算效率,本文确定网络结构为 4 层,训练周期为 250。

3 算例分析

本文以某 220 kV 变压器油色谱在线监测装置 2010 年 10 月 7 日到 2013 年 3 月 24 日的油色谱数据为例,监测周期为 1 d。将 2010 年 10 月 7 日到 2012 年 12 月 14 日的 800 组监测数据作为训练样本,将 2012 年 12 月 15 日到 2013 年 3 月 24 日的 100

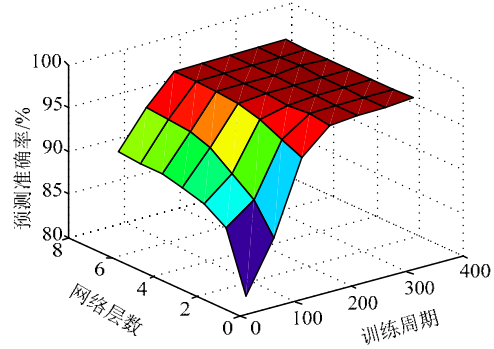


图 4 不同层数、训练周期与预测准确率的关系
Fig. 4 Relationship of different layers, training cycles and prediction precision

组监测数据作为预测样本。
预测评价准则采用平均相对百分误差，其表达式为

$$\delta = \frac{1}{N} \sum_{t=1}^N \left| \frac{\hat{x}_t - x_t}{x_t} \right| \times 100\% \quad (10)$$

最大相对百分误差，其表达式为

$$\max \delta = \max \left| \frac{\hat{x}_t - x_t}{x_t} \right|, \quad t = 1, 2, \dots, N \quad (11)$$

式中： N 为测试样本个数； \hat{x}_t 为预测值； x_t 为实测值。文中以乙烯 C_2H_4 浓度预测结果为例进行说明。
由图 5 可以看出 ,MDBN 网络结构具有更好的


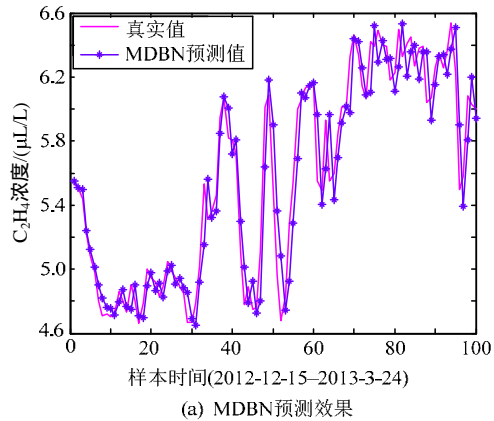


图 5 预测效果及对比
Fig. 5 Prediction results of MDBN and comparison with DBN

预测效果,对于数据具有更好的拟合和预测能力。与未考虑关联因素的单变量 DBN 预测结果比较,在样本数据出现频繁波动时,MDBN 通过提取变量间相互耦合关系,能够更好地跟踪数据变化趋势,预测效果的鲁棒性更强。

将本文所提的 MDBN 预测方法与灰色模型(gray model, GM)、径向基神经网络(radial basis function neural network, RBFNN)、支持向量机(support vector machine, SVM)预测方法的结果进行比较,部分计算结果见表2。MDBN 测试平均相对误差为 2.48%,最大测试误差为 8.59%,基于关联因素的多变量预测方法无论是平均预测误差还是最大预测误差均优于其他预测方法,精度更高。

为分析训练样本对预测效果的影响,分别测试了 100、200、400、600、800 组训练数据的预测情况。由表 3 可知,在小样本情况下,MDBN 同 GM、RBFNN、SVM 预测效果相当,但随着训练样本个数的增加,MDBN 模型提取的趋势特征及关联特征更全面细致,预测误差降低幅度明显优于其他 3 种方法。

同理,采用 MDBN 模型以 2010 年 10 月 7 日至 2013 年 3 月 24 日的数据为例对其他几种气体浓度预测,预测效果如表 4 所示。由表 4 可知,MDBN 方法的预测平均误差均低于 GM、RBFNN、SVM 方法,具有较高的预测稳定性和可靠性。

表 2 C_2H_4 预测结果比较
Tab. 2 Prediction results of C_2H_4 by different methods

时间	真实值/ ($\mu\text{L/L}$)	MDBN/ ($\mu\text{L/L}$)	GM/ ($\mu\text{L/L}$)	RBFNN/ ($\mu\text{L/L}$)	SVM/ ($\mu\text{L/L}$)
2012-12-15	5.53	5.549	5.717	5.618	5.653
2012-12-31	4.66	4.705	4.805	4.759	4.772
2013-01-15	5.02	4.917	4.753	4.820	4.798
2013-01-31	6.01	5.639	5.499	5.530	5.511
2013-02-15	5.93	5.629	5.429	5.473	5.444
2013-02-28	6.49	6.291	6.233	6.267	6.244
2013-03-15	6.35	6.328	6.327	6.325	6.329
2013-03-24	6.00	5.942	5.916	5.935	5.921
平均误差%	—	2.480	4.660	3.560	3.890
最大误差%	—	8.590	11.98	10.01	10.04

注:表中仅列举 8 个时间样本真实值和预测值,平均误差和最大误差依据 2012-12-15—2013-03-24 的总体预测样本计算而来。

表 3 不同训练集对预测效果的影响
Tab. 3 Prediction results of different training sets

训练样本个数	平均预测误差%			
	MDBN	GM	RBFNN	SVM
100	6.51	6.63	6.82	6.38
200	5.21	5.26	5.35	5.22
400	3.72	4.99	4.48	4.64
600	2.98	4.75	3.87	4.23
800	2.48	4.66	3.56	3.89

表 4 其他特征气体浓度预测结果
Tab. 4 Prediction results of other gases

特征气体	平均误差%			
	MDBN	GM	RBFNN	SVM
H_2	2.32	4.83	3.17	3.76
CH_4	1.43	3.95	2.59	3.03
C_2H_6	1.57	4.11	2.98	2.93
C_2H_2	2.16	4.50	3.42	3.77
CO	2.78	5.48	4.74	5.15
CO_2	3.34	6.22	5.71	5.49

4 结论

在变压器油中溶解气体浓度预测中,各气体组分间及气体含量与环境因素有一定的相关性,基于这一思想,本文提出了基于深度信念网络的多变量预测模型。该模型具有如下特点:

1) 基于深度信念网络理论,该模型自动提取输入数据间的特征信息,统计状态量的变化趋势,与传统预测方法相比具有更好的泛化能力,避免了因主观选择阈值而引入误差。

2) 考虑气体含量与气体组分及油温和环境温度的相关性,比单一气体含量预测方法更加科学,尤其是数据频繁波动时,拟合能力更强,预测精度更高。

3) 随着训练集的增大,基于深度信念网络的油中溶解气体浓度预测准确率提高。然而文中油中溶解气体浓度数据量有限,无法得到大数据平台下预测精度提升情况。因此,下一阶段将重点研究电力大数据下 MDBN 预测模型的改进及应用。

参考文献

- [1] 董其国. 电力变压器故障与诊断[M]. 北京:中国电力出版社,2001: 37.
- [2] 魏振,齐波,左健,等. 基于局部放电图像特征的换流变压器油纸绝缘缺陷诊断方法[J]. 电网技术,2015,39(4): 1160-1166. Wei Zhen, Qi Bo, Zuo Jian, et al. A method to diagnose defects in oil-paper insulation of converter transformer based on image feature of partial discharge[J]. Power System Technology, 2015, 39(4): 1160-1166(in Chinese).
- [3] 刘凯,王鹏,王伟,等. 直流电场下变压器油中电场分布特性[J]. 电网技术,2015,39(6): 1714-1718. Liu Kai, Wang Peng, Wang Wei, et al. Electric field distribution in transformer oil under DC electric field[J]. Power System Technology, 2015, 39(6): 1714-1718(in Chinese).
- [4] 吴广宁,姚梦熙,辛东立,等. 油浸绝缘纸在不均匀热老化下的试验研究[J]. 电网技术,2015,39(11): 3298-3304. Wu Guangning, Yao Mengxi, Xin Dongli, et al. Experimental study on oil-impregnated paper with non-uniform thermal aging[J]. Power System Technology, 2015, 39(11): 3298-3304(in Chinese).
- [5] 徐征宇,汪可,孙建涛,等. 直流电压下油纸绝缘局部放电发展过程的潜伏期特征[J]. 电网技术,2016,40(2): 614-619. Xu Zhengyu, Wang Ke, Sun Jiantao, et al. Research on characteristics during latent period of partial discharge developing process under

- direct voltage of oil-paper insulation[J]. Power System Technology, 2016, 40(2): 614-619(in Chinese).
- [6] 罗运柏, 于萍, 宋斌, 等. 用灰色模型预测变压器油中溶解气体的含量[J]. 中国电机工程学报, 2001, 21(3): 65-69.
- Luo Yunbai, Yu Ping, Song Bin, et al. Prediction of the gas dissolved in power transformer oil by the grey model[J]. Proceedings of the CSEE, 2001, 21(3): 65-69(in Chinese).
- [7] 付宝英. 基于粒子群优化的变压器故障诊断与预测研究[D]. 福州: 华侨大学, 2012.
- [8] 卞建鹏, 廖瑞金, 杨丽君. 应用弱化缓冲算子与最小二乘支持向量机的变压器油中溶解气体浓度预测[J]. 电网技术, 2012, 36(2): 195-199.
- Bian Jianpeng, Liao Ruijin, Yang Lijun. Concentration prediction of gases dissolved in transformer oil based on weakening buffer operator and least square support vector machine[J]. Power System Technology, 2012, 36(2): 195-199(in Chinese).
- [9] 杨延方, 刘沛, 李浙, 等. 应用新型多方法组合预测模型估计变压器油中溶解气体浓度[J]. 中国电机工程学报, 2008, 28(31): 108-113.
- Yang Tingfang, Liu Pei, Li Zhe, et al. A new combination forecasting model for concentration prediction of dissolved gases in transformer oil[J]. Proceedings of the CSEE, 2008, 28(31): 108-113(in Chinese).
- [10] 肖燕燕, 朱衡君, 陈秀海. 用灰色多变量模型预测变压器油中溶解的气体浓度[J]. 电力系统自动化, 2006, 30(13): 64-67.
- Xiao Yancai, Zhu Hengjun, Chen Xiuhai. Concentration prediction of dissolved gas-in-oil of a power transformer with the multivariable grey model[J]. Automation of Electric Power Systems, 2006, 30(13): 64-67(in Chinese).
- [11] 司马莉萍, 舒乃秋, 左婧, 等. 基于灰关联和模糊支持向量机的变压器油中溶解气体浓度的预测[J]. 电力系统保护与控制, 2012, 40(19): 41-46.
- Sima Liping, Shu Naiqiu, Zuo Jing, et al. Concentration prediction of dissolved gases in transformer oil based on grey relational analysis and fuzzy support vector machines[J]. Power System Protection and Control, 2012, 40(19): 41-46(in Chinese).
- [12] 林湘宁, 黄京, 熊卫红, 等. 变压器油中溶解气体浓度的区间预测[J]. 电力自动化设备, 2016, 36(4): 73-77.
- Lin Xiangning, Huang Jing, Xiong Weihong, et al. Interval prediction of dissolved-gas concentration in transformer oil[J]. Electric Power Automation Equipment, 2016, 36(4): 73-77(in Chinese).
- [13] 唐勇波, 桂卫华, 彭涛, 等. 基于互信息变量选择的变压器油中溶解气体浓度预测[J]. 仪器仪表学报, 2013, 34(7): 1492-1498.
- Tang Yongbo, Gui Weihua, Peng Tao, et al. Prediction method for dissolved gas concentration in transformer oil based on variable selection of mutual information[J]. Chinese Journal of Scientific Instrument, 2013, 34(7): 1492-1498(in Chinese).
- [14] 石鑫, 朱永利, 萨初日拉, 等. 基于深度信念网络的电力变压器故障分类建模[J]. 电力系统保护与控制, 2016, 44(1): 71-76.
- Shi Xin, Zhu Yongli, Sa Churila, et al. Power transformer fault classifying model based on deep belief network[J]. Power System Protection and Control, 2016, 44(1): 71-76(in Chinese).
- [15] 张新伯, 唐炬, 潘成, 等. 用于局部放电模式识别的深度置信网络方法[J]. 电网技术, 2016, 40(10): 3272-3278.
- Zhang Xinbo, Tang Ju, Pan Cheng, et al. Research of partial discharge recognition based on deep belief nets[J]. Power System Technology, 2016, 40(10): 3272-3278(in Chinese).
- [16] 周晓莉, 张丰, 杜震洪, 等. 基于CRBM算法的时间序列预测模型研究[J]. 浙江大学学报(理学版), 2016, 43(4): 442-451.
- Zhou Xiaoli, Zhang Feng, Du Zhenhong, et al. A study on time series prediction model based on CRBM algorithm[J]. Journal of Zhejiang University(Science Edition), 2016, 43(4): 442-451(in Chinese).
- [17] Hinton G, Simon O, Yee-Whye T. A fast learning algorithm for deep belief nets[J]. Neural Computation, 2006, 18(7): 1527-1554.
- [18] Hinton G, Salakhutdinov R.R. Reducing the dimensionality of data with neural networks[J]. Science, 2006(313): 504-507.
- [19] 余滨, 李绍滋, 徐素霞, 等. 深度学习: 开启大数据时代的钥匙[J]. 工程研究——跨学科视野中的工程, 2014, 6(3): 233-243.
- Yu Bin, Li Shaozi, Xu Suxia, et al. Deep learning: a key of stepping into the era of big data[J]. Journal of Engineering Studies, 2014, 6(3): 233-243(in Chinese).
- [20] 鄞勇, 熊庆宇, 石为人, 等. 一种基于受限玻尔兹曼机的说话人特征提取算法[J]. 仪器仪表学报, 2016, 37(2): 256-262.
- Feng Yong, Xiong Qingyu, Shi Weiren, et al. Speaker feature extraction algorithm based on restricted Boltzmann[J]. Chinese Journal of Scientific Instrument, 2016, 37(2): 256-262(in Chinese).
- [21] Bengio Y. Learning deep architectures for AI[J]. Foundations and Trends in Machine Learning, 2009, 2(1): 1-127.
- [22] Smolensky P. Information processing in dynamical systems: foundations of harmony theory[M]. Cambridge: MIT Press, 1986: 12-23.
- [23] Salakhutdinov R.R, Hinton G. An efficient learning procedure for deep Boltzmann machines[J]. Neural Computation, 2012, 24(8): 1967-2006.
- [24] Hinton G. Training products of experts by minimizing contrastive divergence[J]. Neural Computation, 2002, 14(8): 1771-1800.



代杰杰

收稿日期: 2016-10-12。

作者简介:

代杰杰(1986), 女, 通信作者, 博士研究生, 研究方向为输变电设备状态评估, E-mail: secess@163.com;

盛戈峰(1974), 男, 博士, 副教授, 研究方向为智能输变电技术, E-mail: shenghe@sju.edu.cn。

(责任编辑 马晓华)